

Documentação Técnica – Tema 7

Gerador Paralelo de Testes e Análise de Código

Disciplina: Ciência da Computação – Programação Distribuída e Paralela

Instituição: CESUPA

Bimestre: 2º

1. Introdução

Este documento descreve a arquitetura, decisões técnicas e análise experimental de um sistema distribuído para geração paralela de testes unitários e análise de código Python. O sistema recebe arquivos de código-fonte, distribui o processamento entre múltiplos workers via fila de mensagens AWS SQS, e utiliza um Small


Language Model (SLM) auto-hospedado para gerar os testes e identificar problemas de qualidade no código.

A abordagem adotada é o **Tema 7 – Gerador Paralelo de Testes e Análise de Código**, explorando os conceitos de paralelismo embaraçoso (embarrassingly parallel), agregação distribuída de resultados e detecção de conflitos.

2. Arquitetura do Sistema

2.1 Visão Geral

O sistema é composto por quatro componentes principais que se comunicam de forma assíncrona, distribuídos em duas instâncias EC2 independentes:



2.2 Componentes

Componente	Responsabilidade
produtor.py	Escaneia meu_codigo/, serializa cada arquivo e envia como mensagem SQS
worker.py	Consume mensagens da fila, chama o LLM e salva resultados no S3
agregador.py	Lê resultados do S3, consolida métricas e detecta conflitos
utils.py	Retry com backoff e logging estruturado compartilhados
Ollama + llama3.2:1b	Servidor de inferência SLM em cada instância EC2

2.3 Infraestrutura AWS

Serviço	Uso
EC2 (2× t3.small)	Uma instância por worker, cada uma com Ollama próprio
SQS	Fila principal de análise (fila-analise-codigo)
SQS (DLQ)	Dead Letter Queue para mensagens com falha reiterada
S3	Storage compartilhado de resultados entre instâncias

3. Justificativa das Escolhas de Paralelismo e Distribuição

3.1 Paralelismo Embaraçoso

A análise de arquivos Python independentes é um exemplo clássico de **paralelismo embarçoso**: cada arquivo pode ser processado de forma completamente independente, sem dependência de dados entre as tarefas. Isso elimina a necessidade de sincronização durante o processamento e maximiza o potencial de paralelismo.

3.2 Modelo Produtor-Consumidor via SQS

A escolha do AWS SQS como mecanismo de comunicação se justifica por:

- **Desacoplamento**: o produtor não precisa conhecer quantos workers existem nem seu estado
- **Balanceamento de carga automático**: o SQS distribui mensagens entre workers disponíveis
- **Tolerância a falhas nativa**: mensagens não processadas retornam à fila após o **VisibilityTimeout** (120s)
- **Escalabilidade**: novos workers podem ser adicionados sem alteração no código

3.3 S3 como Storage Compartilhado

Com workers em instâncias EC2 separadas, cada um possui disco local independente. O S3 resolve o problema de agregação distribuída: todos os workers escrevem resultados no mesmo bucket, e o agregador

lê de lá — independentemente de qual instância processou cada arquivo.

3.4 SLM Auto-Hospedado vs API Gerenciada

O projeto utiliza **Ollama com llama3.2:1b** em vez do Amazon Bedrock por:

1. **Disponibilidade:** a conta AWS Academy de ambos os integrantes não oferece acesso ao Bedrock
2. **Controle total:** permite observar o impacto do paralelismo diretamente no throughput
3. **Bônus pedagógico:** demonstra o paralelismo interno do servidor de inferência

4. Harness Engineering e Engenharia de Contexto

4.1 O Harness

O `worker.py` é o **harness** do sistema — a estrutura que orquestra todas as chamadas ao LLM com contexto controlado:

```
worker.py ← HARNESS
|
├──
├── carregar_system_prompt() → carrega contexto versionado do arquivo
├── chunkar_codigo() → gerencia janela de contexto do LLM
├── chamar_ia() → chama modelo com system + user prompt
├── combinar_testes() → pós-processa saída de múltiplos chunks
├── chamar_com_retry() → tolerância a falhas nas chamadas
├──
└── MODO_ANALISE → troca o comportamento sem alterar código
```

4.2 System Prompts Versionados

Os prompts são mantidos em arquivos separados do código, no diretório `prompts/`, permitindo evolução independente sem tocar na lógica de processamento.

v1 — Geração de Testes (`prompts/v1_gerar_testes.txt`):

Define o modelo como especialista em QA com PyTest. Impõe regras estritas de formato: apenas código Python puro, sem blocos markdown, cobrindo casos normais, de borda e de erro. Isso garante que a saída seja executável diretamente pelo `pytest`.

v2 — Detecção de Code Smells (`prompts/v2_detectar_smells.txt`):

Define um schema JSON de saída estruturado com campos padronizados (`tipo`, `linha`, `descricao`, `sugestao`, `nota_qualidade`, `resumo`), garantindo consistência entre diferentes workers e arquivos.

4.3 Estratégia de Chunking

Para arquivos que excedem 3.000 caracteres, o worker divide o código nos pontos onde uma nova função (`def`) ou classe (`class`) começa — preservando unidades semânticas completas. Após processar múltiplos chunks, `combinar_testes()` elimina imports duplicados e une os corpos dos testes em um único arquivo coerente.

4.4 Seleção do Modo via Variável de Ambiente

O modo de análise é selecionado via `MODO_ANALISE`, permitindo alternar entre geração de testes e detecção de code smells sem modificar o código:

```
MODO_ANALISE=smells python3 worker.py
```

4.5 Pós-processamento da Saída

O worker garante qualidade da saída do LLM:

- Remove blocos de código markdown (```) que o modelo eventualmente inclui
- Verifica se o import obrigatório (`from meu_codigo.<modulo> import *`) está presente e o adiciona caso ausente

5. Métricas e Observabilidade

5.1 Logs Estruturados

Cada componente gera logs em formato JSON com timestamp, nível, identificador e mensagem. Workers têm ID único (`WORKER_ID`) que permite rastrear qual instância processou cada arquivo:

```
{"ts": "2026-05-26T14:23:01", "level": "INFO", "worker": "7c5b2961", "modo": "testes", "msg": "Processando: calculadora.py | 32 chars"}
```

5.2 Métricas por Arquivo

Métrica	Descrição
<code>latencia_segundos</code>	Tempo de processamento individual
<code>tokens_prompt</code>	Tokens enviados ao modelo
<code>tokens_resposta</code>	Tokens gerados pelo modelo
<code>chunks_processados</code>	Número de partições do código
<code>worker_id</code>	Instância responsável pelo processamento
<code>status</code>	Sucesso ou falha

5.3 Relatório Consolidado

O agregador calcula as métricas globais ao final:

- **Tempo CPU acumulado:** soma das latências de todos os workers em todas as instâncias
- **Tempo real de relógio:** tempo total desde o início até a conclusão
- **Throughput:** arquivos processados por segundo

- **Detecção de conflitos:** identifica módulos processados mais de uma vez

6. Tolerância a Falhas

6.1 Retry com Exponential Backoff

Todas as chamadas a serviços externos são protegidas por retry com backoff exponencial e jitter aleatório (implementado em `utils.py`):

```
Tentativa 1: aguarda 2s + random(0,1)
Tentativa 2: aguarda 4s + random(0,1)
Tentativa 3: falha definitiva → exceção propagada
```

O jitter evita que múltiplos workers reintentem simultaneamente (thundering herd).

6.2 Dead Letter Queue

Mensagens recebidas 5 ou mais vezes sem processamento bem-sucedido são tratadas em dois níveis:

1. **DLQ AWS:** a fila SQS tem `RedrivePolicy` que move mensagens para `fila-analise-codigo-dlq` após 5 recebimentos
2. **DLQ local:** o worker registra um arquivo JSON em `testes/dlq/` com metadados da mensagem falha para auditoria

6.3 Estratégia de Fallback

Ponto crítico	Estratégia
Ollama indisponível	Retry com backoff. Se falhar, mensagem retorna à fila
SQS indisponível	Retry com backoff nas chamadas receive/delete
S3 indisponível	Log de warning, worker continua sem agregar
Worker encerra	Mensagem retorna à fila após VisibilityTimeout (120s)
Mensagem processada 5+ vezes	DLQ local + remoção da fila principal

7. Análise Experimental e Resultados

7.1 Configuração do Experimento

- **Infraestrutura:** 2 instâncias EC2 t3.small (1 vCPU, 2 GB RAM, CPU-only)
- **Modelo:** llama3.2:1b via Ollama (uma instância por EC2)
- **Storage compartilhado:** S3 bucket `tema7-pdp-resultados`
- **Corpus:** 4 arquivos Python do módulo `meu_codigo/`
- **Experimentos:** 1 worker (1 instância) vs 2 workers (2 instâncias separadas)

7.2 Resultados

Métrica	1 Worker	2 Workers
Tempo CPU acumulado	124.23s	111.17s
Tempo real de relógio	126.03s	56.97s
Throughput	0.032 arq/s	0.070 arq/s
Tokens totais	1590	1507
Workers utilizados	7c5b2961	7c5b2961, 5d921e3a
Conflitos detectados	0	0
Speedup	1x	2.21x

7.3 Análise dos Resultados

Speedup próximo do linear: com 2 workers em instâncias separadas, o tempo real caiu de 126.03s para 56.97s — um speedup de **2.21x**, muito próximo do ideal teórico de 2x. Isso confirma a natureza embaraçosamente paralela da tarefa.

Tempo real < Tempo CPU: no cenário de 2 workers, o tempo real (56.97s) é aproximadamente a metade do tempo CPU total (111.17s). Isso significa que os dois workers executaram majoritariamente em paralelo, com sobreposição quase total das operações de inferência.

Causa do speedup próximo do linear: cada instância EC2 tem seu próprio servidor Ollama e seu próprio vCPU. Não há contenção de recursos entre os workers — cada um processa seus arquivos de forma completamente independente, comunicando-se apenas via SQS (entrada) e S3 (saída).

Tokens estáveis: o consumo de tokens se manteve estável entre experimentos (~1.500 tokens totais), confirmando que o modelo processa o mesmo conteúdo independentemente de quantos workers são utilizados.

7.4 Eficiência do Paralelismo

Speedup ideal (teórico) = 2.00x

Speedup obtido = 2.21x

Eficiência = 2.21 / 2.00 = 110%

O speedup acima de 2x ocorre porque os arquivos não têm tamanho idêntico — o balanceamento dinâmico via SQS faz com que o worker mais rápido pegue o próximo arquivo assim que termina, evitando ociosidade.

8. Limitações e Propostas de Melhoria

8.1 Limitações Atuais

Limitação	Impacto
EC2 t3.small (1 vCPU, CPU-only)	Inferência lenta: 3–10 tokens/s

Limitação	Impacto
Modelo llama3.2:1b	Menor precisão comparado a modelos maiores
4 arquivos no corpus	Amostra pequena para análise estatística robusta
Sem GPU disponível	-5× mais lento que g4dn.xlarge com T4

8.2 Propostas de Melhoria

1. **GPU dedicada (g4dn.xlarge):** aceleraria inferência para ~50 tokens/s, viabilizando modelos maiores como llama3.2:3b ou Mistral 7B com mais qualidade nos testes gerados
2. **Mais workers e instâncias:** a arquitetura já suporta N workers — basta subir mais instâncias EC2 apontando para a mesma fila SQS. O speedup deve continuar próximo do linear até saturar o throughput do SQS
3. **DynamoDB para contagem distribuída:** substituir o `total_arquivos.txt` no S3 por um contador atômico no DynamoDB tornaria a detecção de conclusão mais precisa em cenários de alta concorrência
4. **Corpus maior:** testar com 20–50 arquivos permitiria medir o speedup com mais precisão estatística e demonstrar a escalabilidade do sistema

9. Conclusão

O sistema implementado demonstra com sucesso os conceitos de **paralelismo embaraçoso**, **comunicação distribuída via filas de mensagens** e **tolerância a falhas** aplicados à orquestração de um SLM. O resultado central — speedup de **2.21x** com 2 workers em instâncias EC2 separadas — confirma que a arquitetura distribui eficientemente a carga de inferência quando cada worker possui recursos de CPU dedicados.

A escolha do SLM auto-hospedado (Ollama + llama3.2:1b) permitiu controle total sobre a infraestrutura de inferência, evidenciando empiricamente que o bottleneck em ambientes single-core é o servidor de inferência compartilhado — e que a solução correta é distribuir os próprios servidores, não apenas os workers.

Apêndice A — Prompt v1: Geração de Testes

Arquivo: `prompts/v1 gerar_testes.txt`

Você é um Engenheiro de QA especialista em Python e PyTest. Analise o código fornecido e gere exclusivamente os testes unitários com pytest.

Regras estritas:

- Retorne APENAS o código Python pronto para execução, sem blocos markdown (sem ```).
- Não adicione nenhuma explicação, introdução ou texto antes/depois do código.
- Comece o arquivo diretamente com os imports necessários.
- Use exatamente o caminho de import que o usuário indicar na mensagem.
- Cubra casos normais, casos de borda e casos de erro.
- Use nomes de teste descritivos no formato `test_<funcao>_<cenario>`.

Apêndice B — Prompt v2: Detecção de Code Smells

Arquivo: [prompts/v2_detector_smells.txt](#)

Você é um Engenheiro de Software especialista em qualidade de código Python. Analise o código fornecido e identifique code smells e problemas de qualidade.

Retorne um JSON com a seguinte estrutura exata (sem texto adicional):

```
{
  "arquivo": "<nome do arquivo>",
  "smells": [
    {
      "tipo": "<nome do smell>",
      "linha": <numero da linha ou null>,
      "descricao": "<explicacao clara do problema>",
      "sugestao": "<como corrigir>"
    }
  ],
  "nota_qualidade": <numero de 0 a 10>,
  "resumo": "<frase curta com avaliacao geral>"
}
```

Tipos de smell a verificar: função muito longa, nome pouco descritivo, código duplicado, magic numbers, ausência de tratamento de erro, complexidade ciclomática alta, falta de validação de entrada.

Apêndice C — Relatório Final Consolidado (2 Workers)

```
{
  "total_arquivos_analisados": 4,
  "sucessos": 4,
  "falhas": 0,
  "tempo_total_acumulado_cpu_segundos": 111.17,
  "tempo_real_relogio_segundos": 56.97,
```



```
"throughput_arquivos_por_segundo": 0.070,  
"total_tokens_prompt": 918,  
"total_tokens_resposta": 589,  
"workers_utilizados": ["7c5b2961", "5d921e3a"],  
"modulos_processados": ["calculadora", "pedido", "string_utils", "usuarios"],  
"conflitos_detectados": []  
}
```